# 海洋能源战略智能智库需求规格与实施方案

版本 1.0 | 调研日期 2026 年 10 月 7 日 | 面向产品、研发、领域研究与采购人员

以现有战略驾驶舱为业务入口，建设“可持续采集、可检索、可核验、可计算”的海洋能源研究系统。推荐保留 Nuxt、PostgreSQL、pgvector 和 ECharts，先建立原文证据、事件与指标底座，再增加混合检索和受控智能体。模型负责识别、归纳和解释；关系确认、数值计算、权限控制及引用校验由明确规则与服务完成。

交付按三步推进：①核查并接入可用信息源；②把文章转化为事件、实体、关系、指标、时间序列和空间信息，实现中文混合检索；③将可靠数据接入现有八个模块，形成可审核的战略研究、可追溯图表和持续订阅。本文的技术参数与验收值是项目建议，不是已经达到的线上指标。

## 1 现状与建设边界

基线来自 2026-10-07 对网站首页及 /intelligence、/research、/charts、/wechat、/articles、/export、/admin 的只读浏览，以及用户提供的海洋能源主题文件。页面当时展示 128 篇资料、96 条演示事件、12 个来源和 12 个向量片段；这些是演示界面状态，不代表真实采集量、关系准确率或系统吞吐能力。未触发清空数据、同步采集或研究生成操作。[W01]

网站已有战略驾驶舱、事件核验入口、AI 研究工作台、量化分析、公众号与 RSS 管理、资料筛选、邮件订阅及知识库管理。当前工作目录仍包含早期问答与图表实现，不能据此断言远端版本使用同一后端；启动开发时必须先确认实际部署仓库、提交号、表结构及迁移状态。

| 现有模块 | 生产化必须补齐 | 优先级 |
| --- | --- | --- |
| 战略驾驶舱 | 统一文章数、事件数、关系数口径；真实来源覆盖和新鲜度；点击地图回到证据 | P0 |
| 情报事件 | 事件归并、日期精度、核验队列、关系角色、冲突和撤回处理 | P0 |
| AI 研究工作台 | 混合检索、事实与推断分区、逐项引用、研究版本及人工审核 | P0 |
| 量化分析 | 全量受控查询、单位/状态/频率校验、计算来源链，禁止样本外推 | P0 |
| 全球信息感知 | 统一源注册、API/RSS/网页/PDF 连接器、失败告警、增量与重放 | P0 |

| 现有模块 | 生产化必须补齐 | 优先级 |
| --- | --- | --- |
| 情报资料 | 双语原文、规范 URL、版本、转载链、来源主体、段落和表格定位 | P0 |
| 情报订阅 | 基于新增或变化事件去重推送；收件人权限、发送记录、撤回提醒 | P1 |
| 战略知识库 | 实体别名、关系本体、指标字典、模型与索引版本、授权范围和质量评估 | P0 |

首期目标用户为研究人员、审核人员、采集管理员和只读决策用户。首期不承诺全球完整覆盖、实时 AIS 航迹、精确风险预测、无限制第三方社媒读取或未经授权的付费全文。模拟数据独立标识与环境隔离，不参与正式报表。

## 2 海洋能源主题体系与入库规则

一级分类保留用户主题文件的五类，不用前端标签反向压缩研究边界。现有“海上风电、海洋氢能、海洋装备”保留为专题视图：风电和海洋氢能主要映射海洋新能源；装备作为跨领域标签，可同时服务油气、新能源和多能融合。文档允许多标签，但必须有一个主要主题和具体入选依据。

| 一级主题 | 建议二级主题 | 边界与排除 |
| --- | --- | --- |
| 海洋能源资源宏观政策 | 海域准入、能源规划、并网消纳、行业标准、跨国海洋能源合作 | 排除普通企业内部制度、泛园区招商、无能源关联的渔业旅游政策 |
| 海洋油气 | 勘探发现、储量、深水开发、FPSO/FLNG、水下生产、海底管线、海上安全环保 | 排除纯陆地油气、零售油价、无海洋关联的贸易快讯；油价影响研究可入背景库 |
| 海洋新能源 | 固定式/漂浮式风电、海上光伏、海洋氢能、波浪能、潮汐/潮流能、温差能、盐差能 | 区分海水直接制氢、淡化后电解和海上可再生电力制氢；排除陆上风光及传统化工制氢 |
| 海洋多能融合 | 风光储联合、油气平台电气化、海上微电网、能源与淡化、能源与海洋牧场、微藻生物质 | 须有至少两类系统的耦合关系；不能只因一篇文章同时提及风电和油气就归类 |
| 海洋低碳 | 海底地质封存/CCUS、海上甲烷减排、蓝碳生态与方法学、海洋碱化、低碳船舶燃料、岸电 | 按用户范围保留蓝碳和港口低碳；区分核算潜力、核证减排与实际封存；排除纯陆地节能和林业碳汇 |

横向标签：政策与标准、技术成熟度、项目阶段、企业与供应链、海工装备、投融资、生态与安全、国家海域、数据类型。主题词表同时维护中英及葡语别名，例如 floating offshore wind / FOW、FPSO、FLNG、subsea production、ocean thermal energy、CCUS。行业缩写按上下文消歧，避免把 offshore outsourcing 等非海洋含义误收。

- 核心库：有明确海洋能源对象、过程、项目、政策或用户列出的海洋低碳主题，且正文提供可定位依据。
- 背景库：宏观供需、油价、LNG 航运等对指定海上资产或研究问题有明确解释价值；必须记录关联理由，默认不计入海洋项目数量。
- 候选/排除库：只有标题关键词、来源不可核查、与范围不符或正文缺失。正文缺失可作为线索，但不能支撑细粒度关系及数值判断。

分类采用“规则粗筛 → 语义判别 → 原文证据定位 → 人工抽检”。输出 topic_ids、scope_level、inclusion_reason、evidence_span_ids、rule/model_version。低置信度转审核，人工标注优先且保留修改记录；不以某个模型自报置信度作为真实准确率。

# 3 第一步 采集源调研与接入

## 3.1 可获取性结论

技术可读、长期稳定和允许入库是三个独立状态。A 表示本次实际 HTTP 或 XML 解析成功；B 表示官方产品/文档或页面已核查，但未完成生产连接器和授权调用；C 表示受阻或未证实；D 表示候选。RSS 的 A 状态只确认订阅条目，不自动确认全文、图片或模型加工许可。商业 API 的 B 状态不表示已经购买、已调用或具备全部字段。

| 已实测 RSS | 结果与字段 | 生产接入意见 |
| --- | --- | --- |
| Oilprice [S07] | HTTP 200，15 条；标题、链接、GUID、摘要、发布时间、作者 | P0；严格海洋筛选，全文权限另确认 |
| EIA Today in Energy [S12] | HTTP 200，13 条；标题、链接、发布时间、摘要 | P0；作为事实和统计线索 |
| Offshore Energy [S14] | HTTP 200，50 条；类别、作者、链接与发布时间 | P0；正文采集另做抽样 |
| OffshoreWIND [S15] | HTTP 200，50 条；海上风电专题条目 | P0；与同出版体系内容归并 |

单次订阅返回数量不是历史覆盖量，也不是每日产量。测试来自本地 Windows HTTP 客户端，时间戳、最终 URL、响应类型和错误保存在 source-probes-2026-10-07.json。生产服务器的网络、额度和连续稳定性仍需单独验证。

## 3.2 用户指定海外来源的接入决策

| 来源 | 确认的入口 | 采用方式与限制 |
| --- | --- | --- |
| IEA 国际能源署 [S01] | 官方数据目录、报告、按产品授权下载 | B 官方产品已核查，未完成账户调用；不将网站内部接口当作稳定公共 API。区分免费数据集、OMR 等付费产品；海洋相关筛选后入库。 |
| OPEC [S02] | MOMR PDF 与 Excel 附表 | B 官方下载入口已核查；已确认月报及附表下载入口；未确认面向第三方的公开新闻 API 或 RSS。保留报告版本与预测期。 |
| Wood Mackenzie [S03] | Lens Direct 商业 API / 批量下载 | B 官方 API 产品已核查，未获凭据；官方提供 API、批量下载与 GIS 数据交付说明；确认目标资产字段、历史深度、AI 使用权和导出范围。 |
| Rystad Energy [S04] | Spektra API / 商业数据服务 | B 官方 API 产品已核查，未获凭据；官方介绍 API gateway 与 MCP；这不代表所有套餐开放全部原始数据。先索取海上项目样本与数据字典。 |
| Clarksons Research [S05] | API Portal；WOR / OIN / RIN 商业服务 | B 官方商业入口已核查，未获凭据；优先核查平台利用率、日租金、订单和项目字段；AIS、设备数据与研究文章不是同一授权。 |
| Offshore Engineer [S06] | 公开新闻页、newsletter、商业内容合作 | C 网页可检索；本地直接请求 403；未确认官方 RSS/API。普通抓取被拒绝时暂停，不把绕过防护列为生产方案；可申请供稿或以元数据线索代替全文。 |

| 来源 | 确认的入口 | 采用方式与限制 |
| --- | --- | --- |
| Oilprice.com [S07] | RSS | A RSS HTTP 200，15 条条目解析成功；含 title/link/guid/description/pubDate/creator。摘要不等于完整正文；普通油价与陆地油气消息默认进背景库或排除。 |
| Upstream Online [S08] | 订阅文章、企业内容授权 | B 订阅入口已核查；全文/API/RSS 未确认；网页订阅不自动等于机器采集、长期存储或模型加工许可。取得样本与书面范围后再实施连接器。 |
| Shell [S09] | 官方 newsroom / 邮件提醒 | A 页面 HTTP 200；正文适配尚待抽样；优先采集公司公告；本次未确认稳定全站 RSS。页面会动态更新，应检测发布日期与更新日期。 |
| ExxonMobil [S10] | 官方 newsroom / 邮件提醒 | A 页面 HTTP 200；正文适配尚待抽样；按海上项目实体过滤，不将公司全部新闻纳入。保留发布主体与公告 URL。 |
| Petrobras [S11] | 官方新闻社葡语 / 英语页面 | A 页面 HTTP 200；正文适配尚待抽样；多语言同文归并；保留葡语原始版本与英语版本关系。本次未确认公开 RSS/API。 |

采购选择应服务研究问题：装备日租金、利用率与订单优先评估 Clarksons；资产进度、成本与供需可评估 Rystad 或 Wood Mackenzie。先选一个最能补足数据缺口的商业服务做 PoC，不要求同时采购三家。IEA、OPEC 提供宏观基准，但其全国或全球总量不能直接替代海上能源指标。[S01][S02][S03][S04][S05]

社媒作为发现和观点入口，机构官网及原始报告作为优先证据。建立 source organization → verified account → post → linked publication 链。当前未逐一确认截图所列机构的 X/LinkedIn 账号 ID；实施前必须从官网社媒入口核验，不能凭显示名称认定官方，也不沿用截图中的“最高”“最权威”等排名表述。

## 3.3 国内与补充来源

| 来源组合 | 目的 | 状态与行动 |
| --- | --- | --- |
| 国家能源局、生态环境部、自然资源部、中国政府网 [S20][S21][S22][S23] | 政策与规划，保存文号、发布机构、施行日期 | 能源局首页可达；生态环境部浏览可读；自然资源部本地 DNS 失败、政府网本次读取未成功，需环境复核 |
| 国家统计局与官方公开表 [S24] | 宏观统计校验与背景数据 | 首页可达不等于内部接口可用；优先已公开下载表 |
| 中国海油、沿海省市主管部门 [S25][S26] | 本地海上项目、审批、装备与技术 | 候选清单；先完成具体栏目与账号真实性核对 |
| EIA API [S13] | 结构化能源时序与元数据 | 注册免费 Key；PoC 确认海上拆分、频率、单位与分页 |
| Norwegian Offshore Directorate [S16] | 海上设施、许可与碳封存空间数据 | 官方 REST 元数据可读，本地调用超时；解决连通性后测试要素查询及 CRS 转换 |
| EMODnet、IRENASTAT、OES [S17][S18][S19] | 风场空间要素、可再生能源统计、波浪潮汐与海洋能报告 | 官方目录已核查；按数据集逐项测试，不虚构统一 API |
| 公众号、X、LinkedIn、NewsAPI [S27][S28][S29][S30] | 补充国内信息、机构观点和跨媒体发现 | 权限、生产计费及全文范围分别确认；NewsAPI 的 content 可截断至 200 字符，不作为完整正文 |

公众号接入必须区分自有/授权账号和第三方账号。当前发布类官方文档在本次工具环境无法读取，不将其列为已验证的任意公众号读取能力；现有后台同步流程可保留为待验证连接器。第三方内容优先采用机构授权供稿、合法内容服务或人工提交链接；登录失效后进入需人工处理状态，不把绕验证码、共享凭据或非公开接口稳定性写成产品承诺。

## 3.4 源注册与采购验收

| 源注册字段组 | 必填内容 |
| --- | --- |
| 身份 | source_id、发布组织、平台、账号 ID/名称、官网、真实性确认依据、语言、地域、source_family_id |
| 连接 | adapter_type、入口 URL、API 文档、认证引用、分页/游标、刷新周期、允许路径、连接器版本 |

| 源注册字段组 | 必填内容 |
| --- | --- |
| 可用性 | last_probe_at、HTTP/业务码、样本量、覆盖起止时间、fulltext_level、最近成功时间、失败原因 |
| 权利与成本 | 采集/保存/翻译/索引/模型处理/内部展示/导出/再分发权限、保留期、合同或条款版本、按量单价、月预算 |
| 运行责任 | 管理员、业务负责人、优先级、SLA、重试上限、暂停原因、下一次复核日期 |

商业试用须验证：是否有稳定项目/资产 ID；字段含义和单位；历史与修订记录；增量方式；每秒/每日额度；可存储多久；是否允许发送到阿里云模型、生成向量、做研究报告及对外演示；合同终止后的删除要求。价格以书面报价与控制台为准，不以网页阅读订阅替代 API 或 AI 使用授权。

源准入门槛：负责人完成授权范围确认；抽取 20 个不同日期样本验证正文或数据；增量连续跑 7 天并记录成功率与新鲜度；验证断点续传、删除/更正和单源暂停。对更新很少的官方报告，不能用“没有新内容”判定失败。首期拟接入 15—20 个已通过准入的源，其中至少 4 个 RSS、3 个官方网页/PDF、1 个结构化统计源；条件未满足时减少源数，不伪装已接通。

## 3.5 采集与快照流水线

> 源注册与授权核查 → 调度 → 列表/API 增量 → 元数据入库 → 正文/PDF/表格获取
> → 原始快照与哈希 → 正文清洗/语言识别 → 范围筛选 → 文档归并与版本化
> → 双语段落 → 结构化抽取 → 规则校验/人工审核 → 索引与分析投影 → 告警/研究

RSS 以 GUID/规范 URL 去重，使用 ETag/Last-Modified（源支持时）；API 保存游标、水位和业务响应码；网页只抓白名单栏目并检测 DOM 变更；PDF 保存页码、文本层与 OCR 坐标；表格保存表名、表头、行列、脚注和单位。Feed 更新时间不替代文章发布日期。原文仅有日期时保存 day 精度，不凭空补 00:00 为精确时间。

任务使用持久化队列和独立 Worker，状态为 queued/running/succeeded/retryable_failed/blocked/dead_letter。幂等键至少包含 source_item_id、content_hash、pipeline_version。网络/429 重试采用退避并遵循 Retry-After；401/403、授权失效和解析结构大变进入阻断队列。浏览器离开页面不能中断已经受理的后台入库任务。

原文快照建议保存 HTML/PDF/原始 JSON、清洗文本、canonical_url、采集时间与 SHA-256；截图只辅助留证，不能替代机器可定位的文本证据。付费全文或受限内容按许可保存；仅允许元数据时保留链接与书目，不悄悄补抓正文。截图、附件和清洗文本都受同一权限策略保护。

# 4 第二步 知识加工与混合检索

## 4.1 统一的数据对象

| 对象 | 关键字段 | 约束 |
| --- | --- | --- |
| 来源与发布账号 | source_id、platform、organization_id、account_id、account_url、source_family_id、rights_policy_id | 发布机构与承载平台分开；多个转载站不自动算独立来源 |
| 文档与版本 | document_id、version_id、title_original/title_zh、original_url、canonical_url、publisher、author、published_at、updated_at、fetched_at、language、content_hash | 同文多版本保留；发布时间未知可为空并标记精度/推定状态 |
| 原文片段与译文 | span_id、version_id、原文字符区间/页码/表格单元、text_original、text_zh、translation_version | 引用锚点必须对准固定原文版本；译文不是第二条独立证据 |
| 检索片段 | chunk_id、parent_section_id、span_ids、token_count、embedding_model/dimension/version | 不把 UI 摘要作为唯一回答上下文；中英片段可关联同一原文 |
| 实体与别名 | entity_id、type、canonical_name、aliases、外部 ID、国家角色、合并/拆分审计 | 总部国家、注册国家、项目所在地分别保存 |
| 事件与参与方 | event_id、event_type、subject_entity、participants(role)、event_time_start/end、time_precision、status、evidence_ids | 计划/发生/完成/取消分开；一篇多事件与多篇一事件都支持 |

| 对象 | 关键字段 | 约束 |
| --- | --- | --- |
| 事实主张与观点 | assertion_id、subject/predicate/object、qualifiers、polarity、modality、attributed_to、evidence_ids、review_status | 机构观点必须注明提出者；模型推断不冒充来源明示事实 |
| 关系 | relation_id、from/to_entity、predicate、project_id、valid_from/to、assertion_ids、origin_type | 明确项目与时间限定；共现、推断、确认合作不同类型 |
| 指标观测与版本 | observation_id、metric_code、entity_id、value/unit、period、basis、scenario、revision、source_span_ids | 设计/核准/在建/投运能力分开；指标修订不静默覆盖 |
| 空间对象 | geo_id、geometry、source_crs、normalized_crs、precision、location_role、source_evidence | 仅知道国家时不伪造设施坐标 |
| 变化记录 | change_id、object_id、before/after_version、change_type、effective_at、detected_at、reason | 区分真实变化、数据修订、迟到数据和新来源覆盖 |
| 研究与计算 | run_id、query、as_of、filters、retrieval_plan、model/prompt_version、claim_ids、calculation_ids | 报告与图表保存当时所用数据快照 |
| 证据与审核 | evidence_id、version_id、span_id、supports/refutes/context、reviewer/time、superseded_by | 更正、撤回和权限变化触发受影响结论标记 |

建议在现有 articles/sources 基础上新增 document_versions、source_accounts、evidence_spans、translations、entities、entity_aliases、events、event_participants、assertions、relations、metric_definitions、metric_observations、geo_features、change_records、research_runs、report_claims、calculation_runs、review_tasks 和 ingestion_jobs。证据与事件、关系、结论采用关联表建立多对多关系；清晰的关系表是首期知识图谱存储，不要求立刻增加独立图数据库。

## 4.2 溯源契约

每条可交付事实至少具有：来源组织、承载平台、作者/账号、原始文章或数据地址、发布日期及精度、抓取时间、原文版本、原文定位和审核状态。作者、发布日期缺失时明确“未知”，不得用模型补写。数据引用额外保存数据集版本、series/facet、时间范围、行 ID 或受控查询参数与结果哈希；引用 URL 不含 API Key。

转载链按“发现平台 → 发布账号 → 当前文章 → 声称引用的原始文章 → 已核验的原始证据”记录；未获取原始稿时标“原始来源未核验”。同一新闻稿的十次转载只算一个事件来源家族，不能包装成十方交叉印证。文章更正和付费许可撤销须能定位到下游片段、向量、缓存、报告和导出记录。

> 结论/图表 → report_claim / calculation_run → assertion / observation / event
> → evidence_span → document_version → publication/account/platform → original_url
>
> 展示样式：
> [证据 03] 标题 | 发布机构 | 平台与账号 | 发布日期（精度）
> 原始链接 | 原文第 8 段 / PDF 第 12 页 / 表 3 第 5 行
> 原文与中文译文 | 采集时间 | 版本哈希 | 审核状态

## 4.3 关系本体与提取边界

| 关系类型 | 方向与限定条件 | 可作为证据的内容 |
| --- | --- | --- |
| located_in | 项目/设施 → 海域/国家；记录位置精度 | 明确地点或官方空间数据；不从企业总部推断 |
| operates / develops | 组织 → 资产/项目；角色、权益和时间 | 公告明确运营商/开发商；参与研究不等于运营 |
| owns_share | 组织 → 项目；比例、生效区间、交易状态 | 明确股权比例与交易完成状态；拟收购与已持有分开 |
| supplies_to / contracts_for | 供应方 → 项目/客户；设备/服务、合同与数量 | 明确订单、EPC 或供货公告；不能从行业同属推断 |
| partners_with | 组织 ↔ 组织；必须绑定项目/协议、合作阶段 | 签署/有效协议或共同项目事实；意向、备忘录、执行合同分开 |
| funds / invests_in | 机构 → 项目；金额、币种、投入/承诺口径 | 明确投资或融资；总投资不等于本次到账 |
| approves / regulates | 主管机构/政策 → 项目/领域；法域、效力、日期 | 正式批准或有效政策；征求意见与实施分开 |

| 关系类型 | 方向与限定条件 | 可作为证据的内容 |
| --- | --- | --- |
| uses_technology | 项目/设备 → 技术；研究、试验或商用阶段 | 技术方案、验证或运行事实 |
| connects_to / supplies_power_to | 设施 → 设施；物理连接/供电安排、能力和状态 | 海缆、管线、平台供电的明确设计或运行资料 |
| captures / transports / stores_CO2 | 设施 → CO2 来源/运输网络/封存地；量与年度 | 分别记录捕集、运输和封存；禁止一份容量重复计为三份减排 |
| causes_or_affects_claim | 事件/政策 → 受影响对象；由谁提出、条件和证据 | 有明确归因则存来源主张；仅相关性不升级为因果事实 |
| cites / republishes / supersedes | 文档 → 文档/版本；引用/转载/替代 | 源链与修订依据 |
| co_mentions | 实体 ↔ 实体；同段或同文共现、统计窗口 | 仅代表资料共现，不能进入确认合作数量 |
| derived_country_link | 国家 ↔ 国家；基于已核验实体关系的聚合投影 | 展示底层企业、项目和关系；命名为“跨国企业项目合作”，不等于政府协议 |

抽取必须输出主语、谓词、宾语、限定词、原文 span、否定/条件/预计标识、有效时间和证据类型。来源写“考虑合作”时只能形成拟议关系；写“尚未签约”时保留否定，不产生正向合作边。每条关系的首次上线先进入机器提取待核验态，模型不得把自身输出标记为“已核验”。

实体归一流程：外部 ID 精确匹配 → 已审核别名 → 名称加国家/项目/组织上下文候选匹配 → 人工合并。保留原始实体提及，不因一次合并丢失来源。相同缩写、集团与子公司、港口与城市、同名项目需要独立 ID。跨语言别名与翻译后的名称共同参与检索，但不产生新实体。

## 4.4 事件 时间 变化与指标

先按项目/主体、事件类型、时间窗口和证据语义聚合候选事件，再确认归并。签约、最终投资决策、开工、首台并网、全容量投运是不同事件；同一公告在公众号和官网转载可关联同一事件。资料发布于 10 月、描述 8 月发生的事实时，两种日期分别保存；图表切换日期口径必须显式显示。

至少维护四种时间：published_at（发布）、event_time（发生/预计）、valid_time（事实有效区间）、recorded_at（系统何时知道）。历史研究提供两种模式：按事件发生时间回顾、按当时已收录证据复现；不得把后来发布的修订值泄漏进“当时判断”的回测。日期只有年份/月时保存区间与精度，统计按规则归档并提示未知日。

| 指标族 | 推荐指标 | 强制限定 |
| --- | --- | --- |
| 项目规模 | 装机 MW、设计产能 Mtpa、设计产量、项目数 | 规划/核准/在建/已投运；gross/net/equity；海上/陆上 |
| 技术与工程 | 水深 m、机组 MW、验证工况、阶段里程碑 | 额定/实测；试验/商业；里程碑不能随意换算完成百分比 |
| 运营 | 实际产量、发电量 MWh、利用率、停产时长 | 时间段、日历基准、观测覆盖；容量不等于产量 |
| 装备市场 | 订单数、日租金、利用率、交付时间 | 船型/平台型、区域、币种、现货/合同、样本口径 |
| 投资与成本 | 资本开支、项目总投资、阶段到账、单位成本 | 币种、名义/实际价格、基期、汇率来源与日期 |
| 低碳 | 捕集/运输/封存能力及实绩、甲烷强度、核证蓝碳量 | tCO2 与 tCO2e、年度/累计、设计/实际、核证体系、系统边界 |

每个数值保留原始字符串、原始单位、标准化值和转换公式。MW 与 GW 可按确定比例换算；吨 LNG 到体积天然气需要明确热值/密度假设，不默认固定换算。百分比与百分点区分；汇率换算必须引用对应日期的汇率源。区间、“约”“超过”、缺失值和估算值不可压平成精确点值。

变化比较键至少包括 entity_id + metric_code + unit + scope + basis + scenario + period。相同期间值的更正标为 revision；项目从在建到投运标为 state_transition；晚到的旧文章不算新发生事件。同比/环比仅在同口径同频率可比时计算；上期为 0 显示“新增/无有效基数”，上期缺失显示“无法比较”。来源新增造成的文章增长应提示覆盖变化。

## 4.5 外文翻译与阿里云模型分工

| 能力 | 建议方案 | 实现约束 |
| --- | --- | --- |
| 语言与中文化 | 语言检测 + Qwen-MT；术语表、领域提示与翻译记忆 [M03] | 保留原文与中文逐段对应；金额、单位、地名、否定及时间自动比对 |
| 范围分类与实体事件关系提取 | 账户可用且通过评测的 Qwen 文本模型 + JSON Schema [M04] | 核验具体模型/模式支持；Schema 合法不等于事实正确，仍需字段与证据校验 |
| 向量化 | text-embedding-v4，首期统一 1024 维 [M01][M05] | 显式传递受支持的维度；记录模型/维度/版本，禁止不同嵌入空间混查 |

| 能力 | 建议方案 | 实现约束 |
| --- | --- | --- |
| 精排 | qwen3-rerank 或账号验证过的等价重排模型 [M02] | 不同模型端点、地区、批次与文长限制不同；独立适配和限流，不沿用旧接口假设 |
| 研究生成 | 支持受控工具调用的 Qwen 模型 | 只能基于本次证据集合生成；缺失则拒答/降级；数字由计算服务提供 |
| 扫描文件 | 先文本层解析，失败时 OCR；低置信度人工复核 | 表格需连同表头、脚注、页码保存；不能从整页截图无定位地产生确定指标 |

模型选型以实际百炼地域、账户可用模型和锁定版本为准。官方文档确认 text-embedding-v4 是多语言向量模型，支持可配置维度；抽取应由文本生成模型完成，不能把向量模型当作实体关系抽取器。结构化输出文档对 JSON Object 与 JSON Schema 的模型支持有区别，开发必须实测并做 Zod/Ajv 校验。[M01][M04][M05]

原文是事实抽取的最终依据。建议优先原文抽取并生成中文规范名，译文用于阅读与中文关键词检索；在译文中发现的实体/数值必须回链原文 span。翻译版本变化触发对应中文索引重建，但不复制新事件。跨语问答测试中必须覆盖葡语企业公告、英文项目报告和中文研究问题。

技术微调分两层：第一层调整主题词、Schema、检索策略和提示词；真正的模型微调只在有权使用的人工标注数据充足、错误类型稳定后评估。先建立数百篇跨语言校验集及保留测试集，不能承诺少量演示样本即可训练出可靠行业模型，也不能未经内容授权将商业全文用于训练。

## 4.6 从向量库升级为混合检索

```
问题 → 主题/实体/时间/地域/权限解析
  ├─ 词法召回：原名、缩写、项目 ID、文号、中文术语
  ├─ 向量召回：中外文语义、同义概念与段落
  ├─ 结构化召回：事件、关系、状态、指标、地点
  └─ 图关系扩展：仅有证据的相关实体一至两跳
→ 权限与版本过滤 → RRF 融合 → 去重与来源多样性 → rerank
→ 父段/相邻证据补全 → 指标查询计算 → 带逐项引用的中文回答
```

首期采用 PostgreSQL + pgvector + 中文分词后的全文索引/别名字典与 pg_trgm，再加 SQL 结构化检索；英文可用语言分析配置。PostgreSQL 的 ts_rank 不能对外宣称为 BM25。若多语言词法效果或规模压测不达标，再引入 OpenSearch 的 BM25 和语言分析器。权利、租户、项目可见性过滤必须参与检索，不能等内容进入模型后才隐藏。

初始调优值建议每路召回 30—50 条，RRF 合并后保留不超过 120 条候选，精排后选择 12—20 条证据并按 Token 预算补充原文上下文。以上是实验起点，应由评测集确定。RRF 使用排名而非直接相加不同比例的分数；

同文转载降权，关键实体、否定条件、日期及单位优先保留。UI 200 字摘要不得替代推理上下文。

路由规则：找原文优先词法与向量；找跨国合作优先已核验关系与项目参与方；问最近三个月变化先确定时区、截止日和同比区间，再查事件/指标；问装机、投产或投资额时由受控 SQL/计算服务返回结果；问某国态势综合实体、事件、指标和证据覆盖。图谱扩展不能把一条真实边推成未证明的传递关系。

分块保留章节层级与原文 offsets，以模型 Token 而非简单字符数控制长度。正文、标题、表格分开处理；表格切片保留表头与单位。向量写入按文档版本事务化并设置唯一键 (version_id, chunk_index, embedding_version)，重试不重复插入；新模型使用并行索引与别名切换，旧索引可回滚。

### 4.7 研究智能体与引用校验

智能体可调用 search_documents、get_evidence、query_events、query_relations、query_metric_series、compare_periods、build_chart 和 draft_report。所有查询参数需 Schema 校验，数据库工具使用只读账号及白名单查询模板。禁止执行任意生成 SQL、Shell 或网页中的指令；采集内容只作为数据。默认仅检索授权已收录库，临时联网检索需单独开关并标明新发现未核验。

研究结果结构固定为：研究问题与范围、证据覆盖、确认事实、量化变化、来源观点与分歧、分析推断、信息缺口、待核验清单。事实与推断不能混写。每项事实有 evidence_ids；每项数值有 calculation_id 或 observation_ids；每项推断列出前提、推理类型、反例和不确定性，来源只能支持其确实陈述的范围。

引用校验包括证据 ID 存在、用户有权访问、原文 span 存在、数字单位一致、时间适用、是否支持所述主张、是否撤回或被修订。关键句校验失败时重写或标为“证据不足”，不得补造地址、作者、发布日期或统计数。来源之间冲突时并列观点和适用口径，由研究人员裁决。

## 5 第三步 海洋能源战略智能智库功能落地

| 需求编号与功能 | 可操作流程 | 验收要点 |
| --- | --- | --- |
| F01 全球信息感知 | 注册源 → 测试 → 授权/范围确认 → 运行 → 查看失败队列 | 各源显示最近成功时间、抓取/正文/解析分阶段状态；单源停用不影响其他源 |
| F02 情报资料 | 查看中文摘要 → 中外文对照 → 原文快照 → 人工分类/更正 | 显示账号/平台/原文 URL/发布时间/版本；全文缺失显式提示 |
| F03 情报事件 | 文章提取候选 → 查看证据 → 合并/拆分 → 审核 → 形成时间线 | 一篇多事件、多篇一事件；明确发生/公布/预计日期；审核日志可追查 |
| F04 战略知识库 | 实体别名管理 → 关系/指标字典 → 冲突处理 → 索引重建 | 模型输出不直接算已核验；实体合并可撤销；权限继承到缓存与索引 |

| 需求编号与功能 | 可操作流程 | 验收要点 |
| --- | --- | --- |
| F05 全球态势地图 | 主题/国家/时间过滤 → 切换文章/事件 → 点击地点/连线 → 证据列表 | 地图计数与列表相同；共现、已核验关系、预测关联用不同图例 |
| F06 量化分析 | 选择指标/实体/状态/区间 → 查询全量 → 校验可比性 → 图表 → 下载来源表 | 每个数值回到观测与计算；输入样本不足不得生成全库结论 |
| F07 AI 研究工作台 | 明确问题 → 计划与检索 → 证据/计算 → 初稿 → 审核 → 保存版本 | 逐项引用；可见不足与冲突；结果可按当时数据快照复现 |
| F08 情报订阅 | 保存主题/实体/地区 → 选择频率与授权收件人 → 新增/变化摘要 → 推送记录 | 同事件转载不反复提醒；发送前权限复核；人工审批报告才对外发送 |
| F09 研究报告与快照 | 在线预览 → TXT/Word/PDF 导出 → 附证据清单与快照版本 | 预览与下载同源生成；报告含截止时间、口径、文档版本、来源与审核状态 |
| F10 运维与质量 | 监测源可用性、延迟、成本、准确率、积压与备份 | 可暂停失败连接器、重跑单版本、回滚索引；演示数据不混入正式统计 |

## 5.1 地图与图谱的明确语义

地图默认显示已核验事件数，并提供文章数/项目数切换。热点标注“11 篇”或“6 个事件”，不显示无法解释的裸数字；悬停同时列文章数、去重事件数、实体数、时间范围与更新时间。圆点大小只映射当前计数；颜色只映射主题或核验状态之一，并在图例中说明。波纹是展示效果，不代表风险半径。

实体位置区分事件发生地、设施实际位置、机构总部与涉及国家。精确坐标来自原文或可信地理数据并记录出处；只识别到国家时使用国家聚合标记。空间数据入库统一 WGS84/EPSG:4326，同时保留原始 CRS 和转换过程；例如 SODIR 元数据标明 EPSG:4230，不能直接当作 4326。[S16]

连线必须带 relation_type、有效时间、项目及证据数量。实线用于已核验合作/供货等关系，虚线用于资料共现或研究推断，并允许关闭；物理海缆/管线按实际几何绘制，缺失几何时标示意；没有 AIS 数据时不展示实时航迹。点击一条国家连线展示具体机构、项目和原始公告，不将企业合作误标为政府间协议。

关联图谱优先展示当前问题的一至两跳子图，隐藏无证据边；节点可打开实体档案、项目里程碑与指标。关系强度如按项目数计算，须展示计数口径与去重规则。图谱布局位置不表示实际地理距离；地图与关系图各司其职。

## 5.2 关系 变化 量化 可视化闭环

| 研究问题 | 关系与变化 | 量化与可视化 |
| --- | --- | --- |
| 近三个月漂浮式风电与油气平台融合有何变化 | 项目 uses_technology、supplies_power_to；概念/批准/开工/运行状态变化 | 按项目去重计数；供电容量 MW 按状态分组；地图+里程碑+原文侧栏 |
| 巴西海上油气与中国企业合作有哪些进展 | 企业 contracts_for / partners_with，限定项目和合同阶段 | 核验合同数、设备交付数、同币种已披露金额；国家连线点击回到项目 |
| 全球海上 CCUS 进展是否加快 | 封存设施、运输方、捕集来源分别建实体；审批与投运分开 | 设计能力和实际注入量两条序列；不同边界不相加；来源冲突并列 |
| 海工装备供需出现什么信号 | 订单、交付、租约和服务项目之间的关系 | 许可数据中的利用率/日租金与文章信号分屏；无商业指标时只展示线索数量 |
| 不同智库对某技术判断为何分歧 | 观点归属机构；假设、地域、预测期与证据链 | 相同预测期对照、修订轨迹和观点矩阵；不把某机构意见当作已发生事实 |

变化面板的“增加 220%”必须显示本期/上期绝对值、时间范围、来源覆盖与公式。不得由文章数量增长推出产业实力、产能或风险增长。雷达图在指标缺失时保留缺口，不补零；各轴需有定义、归一化基准、窗口和数据覆盖，不让模型任意给国家打分。首期以可核实指标面板替代综合战略排名。

## 5.3 一个端到端验收样例

以下全部为说明数据结构的虚构样例，不是真实项目消息。A 公司与 B 公司对 P 海上风电项目签署设备供货合同，公告发布于 2026-08-03，签约发生于 2026-08-01；原文写项目设计规模 600 MW，预计 2028 年投运。另一篇 2026-09-12 公告将预计投运时间调整至 2029 年，未改变设计规模。

```
文章 D1 v1 → 原文 span S1（签约）；span S2（600 MW，设计）；span S3（预计 2028）
事件 E1 = 设备供货签约，发生日期 2026-08-01，公布日期 2026-08-03
实体 = 公司 A、公司 B、项目 P、项目海域 G
关系 R1 = A supplies_to P；限定：设备合同，证据 S1；B 角色按原文提取
指标 O1 = P.design_capacity = 600 MW；basis=design；evidence=S2
变化 C1 = expected_commissioning_year 2028 → 2029；证据 D1/S3 + D2/S4
图表 = 设计规模不变、预计投运时间后移；禁止显示新增 600 MW 已投运
输出 = “资料表明预计投运时间后移；原因未见明确说明”，逐句附 D1/D2 引用
```

用户问“最近三个月海上风电形势如何，依据是什么”时，先说明截止日与范围，再检索已核验事件和可比指标，展示真实变化及来源覆盖；如果只收录少量项目，结论限定为“已收录项目”，不能概括为全球全行业。缺少投运实绩时明确无法计算新增实际装机。

## 6 技术架构与接口边界

推荐首期架构：现有 Nuxt 前端/API；独立 Node/TypeScript Worker；PostgreSQL 保存事实与版本；pgvector 提供向量召回；PostGIS 管理空间对象；对象存储保存授权原文和附件；Redis/BullMQ 或等价持久化任务队列；阿里云百炼分别处理翻译、抽取、向量、精排与回答。PostGIS、队列和对象存储是新增组件，开发前核查部署环境和运维能力。

模型网关统一管理超时、重试、地域、API Key 引用、Token 与费用；模型凭据仅在服务端，原文权利策略决定能否发送给外部模型。任务执行保存 request_id、模型版本、输入文档版本和结果校验状态，不保存明文密钥。OCR/大文件抽取可作为独立 Python 服务，非首期必需时不增加复杂依赖。

| 服务接口建议 | 输入 | 输出与保护 |
| --- | --- | --- |
| POST /api/source-registry/:id/probe | source_id，已有凭据引用 | 阶段诊断；禁止回传凭据；仅管理员 |
| POST /api/ingestion-jobs | source_id，时间范围，幂等键 | job_id；异步处理；配额控制 |
| GET /api/documents/:id/versions/:v/evidence | span_id，可见性上下文 | 原文/译文与定位；对受限资料降级元数据 |
| GET /api/search | query，主题/实体/时间/地区/权限 | 混合结果、分数来源、版本与证据；内部缓存按权限分区 |
| GET /api/events 与 /api/relations | 实体、状态、关系类型、时间区间 | 规范 ID、角色、核验与证据；默认排除共现合作 |
| GET /api/metrics/series | metric_code，entities，basis，unit，period | 观测与修订、数据缺口；不兼容口径拒绝相加 |
| POST /api/analysis/compare | 白名单指标与比较窗口 | 计算 ID、公式、样本范围、结果和证据集合 |
| POST /api/research-runs | 问题、范围、截止日、已收录/联网开关 | 任务进度 SSE、证据、报告草稿；可中止并保留日志 |

| 服务接口建议 | 输入 | 输出与保护 |
| --- | --- | --- |
| POST /api/reports/:id/export | 已授权报告版本、格式 | 与预览一致的文件及来源清单；导出权限复核 |

现有早期代码需专项核查：问答 Top 5 后去重及 200 字截断、图表仅向模型传前 20 行、published_at 非空假设、超长段落分块、向量写入事务与维度一致性。先在实际远端版本确认是否仍存在，再排改造工单；不得直接按旧代码覆盖当前站点。

## 7 质量评估与验收

验收采用研究人员标注的独立金标准集，至少 300 篇中外文资料、100 个业务问题，覆盖五个主题、转载、修订、否定、数字单位、同名实体及证据不足。按时间和项目分隔训练/开发/测试集，避免同一公告转载进入不同集合造成虚高分数。以下阈值是上线目标，实施 PoC 后签字冻结。

| 验收项 | 建议门槛 | 方法 |
| --- | --- | --- |
| 来源可用性 | 首期准入源连续 7 天任务成功率 ≥95%；失败可追踪 | 按源分别报告；无更新、无权限、正文失败分开统计 |
| 溯源完整性 | 展示/导出事实 100% 有证据 ID 与来源链；未知字段显式空值 | 从回答、图表、关系随机反查固定版本原文 |
| 主题分类 | 核心/背景/排除宏平均 F1 ≥0.90 | 金标准抽检，并报告五个主题各自结果 |
| 实体归一 | precision ≥0.95；错误合并可恢复 | 重点测同名公司、子公司与跨语项目名 |
| 关键关系抽取 | precision ≥0.90，recall ≥0.80 | 对主体、谓词、宾语、项目限定和时间同时判定 |
| 数值抽取 | 数值+单位+状态+期间联合准确率 ≥0.95 | 只比数值相同不算正确 |
| 检索 | Recall@20 ≥0.90；比当前向量基线提高或不劣化 | 按原文定位/关系/变化/跨语问题分别测 |
| 回答忠实性 | 关键事实人工判定有证据支持率 ≥0.95；虚构引用为 0 | 证据 ID 存在只是最低门槛，还需人工检查支持关系 |

| 验收项 | 建议门槛 | 方法 |
| --- | --- | --- |
| 不足与冲突 | 无证据问题正确拒答/降级率 ≥0.95 | 使用缺失、互相矛盾与范围外问题 |
| 量化与图表 | 金额、单位、期间等确定性计算用例 100% 通过 | 覆盖上期零/缺失、重复项目、部分投运、历史修订 |
| 地图一致性 | 地图、筛选列表、导出数量完全一致 | 文章/事件/项目三种计数各测；只知道国家不落精确点 |
| 权限与删除 | 越权检索/引用/导出为 0；受限源停用按策略传播 | 测试缓存、向量、附件和历史报告的撤权链 |
| 性能 | 5 并发参考负载下检索 P95 ≤3 秒；研究任务异步可见 | 统计模型外检索延迟；LLM 完整报告时间单独测量，不承诺实时完成 |

长期监控区分来源新鲜度、解析正确率、主题有效率、待审核积压、引用错误率、每千有效文章成本和每次研究成本。首次上线必须用真实授权资料跑通至少三个端到端案例，并保存人工修订记录；模拟数据只用于界面演示，不能用于证明准确率。

## 8 分阶段实施与资源

| 阶段 | 工作与交付 | 完成条件 |
| --- | --- | --- |
| 第 1 步，第 1—2 周 | 源清单、权利矩阵、4 个 RSS + 官方网页 + 1 个结构化源 PoC；原文快照与主题校验 | 真实来源可采、可定位、可重放；采购/权限阻塞项明确 |
| 第 2 步，第 3—5 周 | 统一模型、双语、实体/事件/关系/指标抽取、审核台、混合检索与评测 | 五主题基本覆盖；关键关系与数字达到约定精度；没有证据的边不能进正式图谱 |
| 第 3 步，第 6—8 周 | 接入八模块、变化分析、地图/图谱、AI 研究、报告与订阅；权限与负载测试 | 通过端到端验收、恢复演练和研究人员试用 |
| 后续增强 | 商业数据、更多语言、复杂图分析、自动化评测、可选模型微调 | 先证明成本收益，再扩展能力与来源 |

资源假设：2 名研发人员（后端/数据与前端/集成）、1 名兼职领域研究审核人员，并有可用运维支持；时间从获取账号、许可、开发环境和样本后起算，商业采购周期不包含在 8 周内。若仍按原截图的 10 月 20 日参赛截

止安排，只能做窄专题真实数据演示：4 个 RSS + 2 个官方源、有限关系类型、人工核验案例及完整证据链，不应宣称完成生产级全球智库。

首个真实闭环优先选“漂浮式风电与海上油气平台融合”或“巴西海上项目与中国企业合作”，兼顾地理关系、里程碑和公开一手公告；题目是否最终选定由领域负责人依据样本量确定。全库持续采集与高价值文档精加工分开，先处理最相关资料，避免对泛能源资讯无差别翻译与向量化。

## 8.1 成本与采购控制

规划示例：每日筛选后 300 篇、每月 9,000 篇、每篇约 3,000 输入 Token，则单份正文嵌入量约 2,700 万 Token。按本次阿里云 text-embedding-v4 北京区公开文本输入价 0.5 元/百万 Token，单纯嵌入约 13.5 元；增加 20% 重试/重建预算约 16.2 元。这只是一个可复算的向量调用示例，不含译文重复嵌入、翻译、抽取、生成、精排、OCR、存储、计算、人工与商业数据费用，不能把它当作系统月总成本。[M01]

总成本模型：API/内容订阅 + 翻译输入输出 + 抽取输入输出 + 向量 Token + 精排查询文档量 + 研究生成 + OCR 页数 + 存储/计算/出口 + 人工审核。每个源与每类模型设置预算上限、单日限流和账单归属。X 采用当前官方按量计费，NewsAPI 免费开发计划不能用于生产；商业研究数据库先拿小范围报价和样本，不预估未经确认的套餐价格。[S28][S30]

基础设施先按目标容量压测再采购。参考试点规模为 10 万文档、约 100 万片段、5 并发研究用户；1024 维 float32 原始向量约 4.1 GB，尚不含索引、文本、数据库和缓存。可用 8 vCPU/32 GB 内存与独立对象存储作为压测起点，非最低保证配置。为线上采集、抽取、研究设置并发隔离，避免长任务占满主站资源。

## 8.2 上线与回滚

新系统采用独立测试库/Schema、Worker 和对象存储前缀。新增表与索引先在测试环境回填，双写或影子查询比较后切换；禁止直接清空线上模拟或正式数据作为迁移步骤。切换前备份数据库、源注册、模型配置和索引版本；数据库更改保持向后兼容，模型与索引切换可回退。

研究报告保存数据截止日、来源版本、参数、公式与模型版本；下游更正时追加修订提示，不静默改掉已经交付的旧报告。备份至少覆盖数据库与原文对象，验证一次恢复演练；生产 RPO/RTO 根据业务时效和费用签字确定。信息源新增、付费内容使用与对外分享分别有清晰责任人。

# 9 开发启动清单

- 确认 39.96.24.170 实际代码版本、数据库迁移和部署负责人，梳理现有事件/关系/研究 API；本需求不直接修改该站点。
- 领域负责人确认五类主题、核心/背景边界、10 个优先研究问题，以及首期允许上线的关系/指标字典。
- 为 4 个已验证 RSS 建 source_registry；抽 20 篇正文逐项核查日期、作者、原文权限和去重情况。

- 申请 EIA Key，核查阿里云地域与模型权限；先跑双语抽取、1024 维向量与精排的 100 篇 PoC。
- 指定需要申请授权的公众号账号与商业源；确认全文、翻译、嵌入、模型加工、内部导出等使用范围。
- 建立证据 span、事件状态、关系审核、指标单位和历史修订表；实现 3 个真实案例后再扩大自动化。
- 用同一冻结测试集比较原向量问答和混合检索；只有达到验收目标才将关系与数值接入驾驶舱。

# 附录 A 信息源调研台账

以下 30 项包含信息源、数据服务与渠道方案，不等于 30 个已经接通的连接器。详细字段同时提供 source-register-2026-10-07.csv；A/B/C/D 定义见 3.1。所有结果只代表本次检查时间，后续需按源重新验证。

## S01 IEA 国际能源署

覆盖：宏观政策、能源统计、CCUS、海上风电背景。接入：官方数据目录、报告、按产品授权下载。优先级：P1。

状态：B 官方产品已核查，未完成账户调用。费用/权限：公开与付费混合；逐数据集确认许可。

不将网站内部接口当作稳定公共 API。区分免费数据集、OMR 等付费产品；海洋相关筛选后入库。

入口：https://www.iea.org/data-and-statistics/data-sets/

核查依据：[S01]

## S02 OPEC

覆盖：油气供需与海洋油气战略背景。接入：MOMR PDF 与 Excel 附表。优先级：P1。

状态：B 官方下载入口已核查。费用/权限：公开下载入口；保存与分发用途待确认。

已确认月报及附表下载入口；未确认面向第三方的公开新闻 API 或 RSS。保留报告版本与预测期。

入口：https://www.opec.org/monthly-oil-market-report.html

核查依据：[S02]

## S03 Wood Mackenzie

覆盖：海上油气、LNG、海上风电项目与资产。接入：Lens Direct 商业 API / 批量下载。优先级：P2。

状态：B 官方 API 产品已核查，未获凭据。费用/权限：商业询价。

官方提供 API、批量下载与 GIS 数据交付说明；确认目标资产字段、历史深度、AI 使用权和导出范围。

入口：https://www.woodmac.com/lens/direct/

核查依据：[S03]

## S04 Rystad Energy

覆盖：海洋项目、成本、产能、能源市场。接入：Spektra API / 商业数据服务。优先级：P2。

状态：B 官方 API 产品已核查，未获凭据。费用/权限：商业询价。

官方介绍 API gateway 与 MCP；这不代表所有套餐开放全部原始数据。先索取海上项目样本与数据字典。

入口：https://www.rystadenergy.com/spektra

核查依据：[S04]

## S05 Clarksons Research

覆盖：海工装备、钻井平台、海上风电、船舶。接入：API Portal；WOR / OIN / RIN 商业服务。优先级：P2。

状态：B 官方商业入口已核查，未获凭据。费用/权限：商业询价。

优先核查平台利用率、日租金、订单和项目字段；AIS、设备数据与研究文章不是同一授权。

入口：https://www.clarksons.com/research/

核查依据：[S05]

## S06 Offshore Engineer

覆盖：海洋工程、FPSO、FLNG、深水项目。接入：公开新闻页、newsletter、商业内容合作。优先级：P1。

状态：C 网页可检索；本地直接请求 403。费用/权限：公开阅读与商业合作待确认。

未确认官方 RSS/API。普通抓取被拒绝时暂停，不把绕过防护列为生产方案；可申请供稿或以元数据线索代替全文。

入口：https://www.oedigital.com/

核查依据：[S06]

## S07 Oilprice.com

覆盖：油气背景与海上项目相关新闻。接入：RSS。优先级：P0。

状态：A RSS HTTP 200，15 条条目解析成功。费用/权限：RSS 可读；全文与 AI 使用范围另确认。

含 title/link/guid/description/pubDate/creator。摘要不等于完整正文；普通油价与陆地油气消息默认进背景库或排除。

入口：https://oilprice.com/rss/main

核查依据：[S07]

## S08 Upstream Online

覆盖：海上油气项目、招标与行业研究。接入：订阅文章、企业内容授权。优先级：P2。

状态：B 订阅入口已核查；全文/API/RSS 未确认。费用/权限：商业订阅或机构许可询价。

网页订阅不自动等于机器采集、长期存储或模型加工许可。取得样本与书面范围后再实施连接器。

入口：https://www.upstreamonline.com/subscription/

核查依据：[S08]

## S09 Shell

覆盖：海上资产、项目投资、LNG 与低碳公告。接入：官方 newsroom / 邮件提醒。优先级：P0。

状态：A 页面 HTTP 200；正文适配尚待抽样。费用/权限：公开网页；使用范围待确认。

优先采集公司公告；本次未确认稳定全站 RSS。页面会动态更新，应检测发布日期与更新日期。

入口：https://www.shell.com/news-and-insights/newsroom.html

核查依据：[S09]

## S10 ExxonMobil

覆盖：海上油田、CCS、项目里程碑。接入：官方 newsroom / 邮件提醒。优先级：P0。

状态：A 页面 HTTP 200；正文适配尚待抽样。费用/权限：公开网页；使用范围待确认。

按海上项目实体过滤，不将公司全部新闻纳入。保留发布主体与公告 URL。

入口：https://corporate.exxonmobil.com/news

核查依据：[S10]

## S11 Petrobras

覆盖：巴西深水油气、FPSO、海上低碳技术。接入：官方新闻社葡语 / 英语页面。优先级：P0。

状态：A 页面 HTTP 200；正文适配尚待抽样。费用/权限：公开网页；编辑用途及 AI 权限需核查。

多语言同文归并；保留葡语原始版本与英语版本关系。本次未确认公开 RSS/API。

入口：https://agencia.petrobras.com.br/en

核查依据：[S11]

## S12 EIA Today in Energy

覆盖：能源事实、海上生产与 LNG 背景。接入：官方 RSS。优先级：P0。

状态：A RSS HTTP 200，13 条条目解析成功。费用/权限：免费获取；逐项核对引用要求。

含标题、链接、日期、摘要；与 S13 的结构化统计互补。

入口：https://www.eia.gov/rss/todayinenergy.xml

核查依据：[S12]

## S13 EIA Open Data

覆盖：产量、天然气、价格、国际能源时序。接入：API v2，注册免费 API Key。优先级：P0。

状态：B 官方 API 文档已核查；未带 Key 调用。费用/权限：免费 Key；具体数据维度需 PoC。

按数据集元数据选择 offshore / geography 等字段；没有海上拆分时禁止将全国总量冒充海洋能源量。

入口：https://www.eia.gov/opendata/documentation.php

核查依据：[S13]

## S14 Offshore Energy

覆盖：海洋油气、海上风电、绿色航运。接入：RSS。优先级：P0。

状态：A RSS HTTP 200，50 条条目解析成功。费用/权限：RSS 可读；全文与 AI 使用范围另确认。

含发布日期、作者与类别；与 S15 可能重叠，不能视为天然独立证据。

入口：https://www.offshore-energy.biz/feed/

核查依据：[S14]

## S15 OffshoreWIND.biz

覆盖：海上风电、基础、船舶、海缆。接入：RSS。优先级：P0。

状态：A RSS HTTP 200，50 条条目解析成功。费用/权限：RSS 可读；全文与 AI 使用范围另确认。

用于提高风电专题覆盖；对 S14 进行 URL、内容和原始消息来源去重。

入口：https://www.offshorewind.biz/feed/

核查依据：[S15]

## S16 Norwegian Offshore Directorate

覆盖：挪威海上油气设施、许可、碳封存及空间信息。接入：FactMaps ArcGIS REST DataService。优先级：P1。

状态：B 官方元数据已读取；本地端点请求超时。费用/权限：开放数据入口；具体数据集许可核查。

浏览工具确认服务元数据；本地 18 秒超时。原始 CRS 为 EPSG:4230，入库须转换；图层分页和字段联调待完成。

入口：https://factmaps.sodir.no/api/rest/services/DataService/Data/FeatureServer?f=pjson

核查依据：[S16]

## S17 EMODnet Human Activities

覆盖：欧洲海上风场、海域与设施空间分布。接入：WFS / WMS / 数据下载。优先级：P1。

状态：B 官方数据集与 WFS 入口已核查。费用/权限：开放目录；按记录许可使用。

WFS 用于要素和属性，WMS 用于地图显示；候选端点 https://ows.emodnet-humanactivities.eu/wfs?，图层 emodnet:windfarms。

入口：https://emodnet.ec.europa.eu/geonetwork/srv/api/records/8201070b-4b0b-4d54-8910-abcea5dce57f

核查依据：[S17]

## S18 IRENASTAT

覆盖：可再生能源装机、发电量背景与对照。接入：PxWeb 数据查询与下载。优先级：P1。

状态：B 官方数据库入口已核查；API 未联调。费用/权限：公开数据入口；按数据库许可。

确认技术分类是否明确区分海上/陆上；本次不把 PxWeb 页面等同已验证生产 API。

入口：https://pxweb.irena.org/pxweb/en/

核查依据：[S18]

## S19 IEA OES

覆盖：波浪能、潮汐能、海洋能政策与技术。接入：官方报告 / 年报下载。优先级：P1。

状态：B 官方出版目录已核查。费用/权限：公开报告；按文档许可。

补足新闻媒体对海洋可再生能源覆盖不足；按章节、页码建立证据。

入口：https://www.ocean-energy-systems.org/publications/

核查依据：[S19]

## S20 国家能源局

覆盖：海上风电、能源规划、行业管理。接入：官网公开栏目 / 政策附件。优先级：P0。

状态：A 首页 HTTP 200；栏目正文待抽样。费用/权限：公开页面；采集规则需核查。

本次未确认开放 API 或官方 RSS。适配政策栏目和 PDF，保留文号、发布与施行日期。

入口：https://www.nea.gov.cn/

核查依据：[S20]

## S21 自然资源部

覆盖：海域使用、海洋资源、蓝碳政策。接入：官网公开栏目及文件。优先级：P1。

状态：C 本地 DNS ENOTFOUND，待换环境复核。费用/权限：待核查。

本次失败只反映本地网络，不认定站点停运；可先录入可核验的官方文件链接。

入口：https://www.mnr.gov.cn/

核查依据：[S21]

## S22 生态环境部

覆盖：海洋生态、甲烷减排、CCUS、蓝碳。接入：官网公开政策、报告。优先级：P0。

状态：B 浏览工具可读；连接器未完成。费用/权限：公开页面；使用规则需核查。

仅收录海洋低碳范围内资料；没有公开 RSS/API 证据时采用网页适配。

入口：https://www.mee.gov.cn/

核查依据：[S22]

## S23 中国政府网政策库

覆盖：国家级海洋能源政策。接入：官方政策网页 / 附件。优先级：P1。

状态：C 本次浏览工具未读出，待接入 PoC。费用/权限：公开入口候选。

与部委原始发布去重；以正文文号与签发机构校准权威来源。

入口：https://www.gov.cn/zhengce/

核查依据：[S23]

## S24 国家统计局

覆盖：能源宏观统计背景。接入：官网发布与可下载统计表。优先级：P1。

状态：A 首页 HTTP 200；具体表未联调。费用/权限：公开入口；按数据集规则。

未确认稳定开放 API；先导入官方公开表。不可由全国能源总量推算海上占比。

入口：https://www.stats.gov.cn/

核查依据：[S24]

## S25 中国海油等海洋能源企业

覆盖：国内海上油气、海工项目与技术。接入：官方新闻 / 公告 / 授权公众号。优先级：P0 候选。

状态：D 候选，待栏目和账号逐项确认。费用/权限：公开与授权混合。

需完成真实发布主体、栏目 URL、账号主体核对；不能因账号名称相似就标官方。

入口：https://www.cnooc.com.cn/

核查依据：[S25]

## S26 沿海省市主管部门

覆盖：海上风电、海域审批、并网、地方政策。接入：按省市建立官网白名单。优先级：P1。

状态：D 候选集合，非单一订阅源。费用/权限：逐源确认。

建议从广东、福建、山东、江苏、浙江、海南选 3 省试点；本行不是已验证 API/RSS。入口仅作能源主管背景参考。

入口：https://www.nea.gov.cn/

核查依据：[S26]

## S27 微信公众号

覆盖：国内行业资讯与机构发布。接入：授权内容、人工链接、合规供稿；自有账号 API。优先级：P0 有条件。

状态：C 官方文档本次无法读取；账号权限待验证。费用/权限：依账号授权或内容合同。

不能把公众号后台会话或发布接口当作任意账号的全量读取 API。现有同步功能需验证连续运行、权限和失效降级。

入口：https://developers.weixin.qq.com/doc/subscription/api/public/api_freepublish_batchget.html

核查依据：[S27]

## S28 X 官方账号

覆盖：机构与企业社媒动态。接入：X API，账号 ID 白名单。优先级：P2。

状态：B 官方计费文档已核查；未认证调用。费用/权限：按资源读取计费，控制台确认。

先从机构官网核验账号，再保存 post ID、作者、发布时间和原始链接；全文报告优先回源官网。

入口：https://docs.x.com/x-api/getting-started/pricing

核查依据：[S28]

## S29 LinkedIn 官方机构页

覆盖：机构观点与企业动态。接入：获批应用与组织权限；官网替代。优先级：P2。

状态：B 官方权限说明已核查；未获授权。费用/权限：受权限及合作条件限制。

不作为任意第三方机构页的稳定采集承诺。首期优先同机构 newsroom 与邮件订阅。

入口：https://learn.microsoft.com/en-us/linkedin/marketing/community-management/community-management-overview

核查依据：[S29]

### S30 NewsAPI

覆盖：跨媒体发现与遗漏补充。接入：Everything API。优先级：P2。

状态：B 官方 API 文档已核查；未带 Key 调用。费用/权限：开发免费仅限开发；生产需付费。

content 字段可能仅 200 字符，不能替代全文证据；名单内站点覆盖、历史跨度和授权另做验证。

入口：https://newsapi.org/docs/endpoints/everything

核查依据：[S30]

## 附录 B 技术依据与文件

M01 阿里云 text-embedding-v4：https://help.aliyun.com/zh/model-studio/text-embedding-v4

M02 阿里云文本重排序：https://help.aliyun.com/zh/model-studio/text-rerank-api

M03 Qwen-MT 翻译模型：https://help.aliyun.com/zh/model-studio/machine-translation/

M04 Qwen 结构化输出：https://help.aliyun.com/en/model-studio/qwen-structured-output

M05 阿里云向量化接口与维度：https://help.aliyun.com/zh/model-studio/embedding

W01 现有网站快照：http://39.96.24.170/

本地依据：用户提供《海洋能源主题参考.txt》；当前仓库 README、server/db/schema.ts、server/api/qa.post.ts、server/api/charts/generate.post.ts 与 server/utils/embedding.ts。线上观察与本地代码分别记录，不假定同步。

随附：source-register-2026-10-07.csv（来源台账）；source-probes-2026-10-07.json（12 个入口的本地只读探测）；本 Word 与 HTML 阅读版由同一内容生成。没有购买订阅、申请账号或调用付费模型；也没有修改被调研网站及其数据库。